

PROYECTO FINAL

Estrategia de Optimización de Costos y Recursos

InmoLead IA

Ecosistema de Atención Inmobiliaria con Inteligencia Artificial

Versión documental: 12/08/2026

1. Estrategia actual del MVP

El workflow usa Gemini 3.5 Flash-Lite para clasificación estructurada y redacción. La selección es coherente con un chatbot de alto volumen: Google lo describe como su modelo GA más costo-eficiente de la familia 3.5 para tareas de alto volumen, ejecución agentic, traducción y procesamiento simple. El orquestador es n8n Community self-hosted en Docker local, por lo que no existe una suscripción n8n Cloud en el prototipo.

Criterio de diseño

Las respuestas al cliente son interactivas y no deben enviarse por Batch. El 50% de ahorro de Batch se reserva para trabajos offline/no urgentes, por ejemplo resúmenes históricos, recalificación nocturna de leads o generación de métricas del dashboard.

2. Precios de referencia vigentes al 12/08/2026

Servicio / modalidad	Precio de referencia	Uso en InmoLead IA
Gemini 3.5 Flash-Lite Standard	\$0.30 / 1M tokens input; \$2.50 / 1M output	Producción interactiva del MVP
Gemini 3.5 Flash-Lite Batch	\$0.15 / 1M input; \$1.25 / 1M output	Propuesto para procesos ofline; 50% menor que Standard
Gemini 3.6 Flash Standard	\$1.50 / 1M input; \$7.50 / 1M output	Alternativa para tareas complejas; no necesaria en el flujo actual
n8n Community self-hosted	Sin licencia n8n; costo = infraestructura propia	Docker local
Notion Free	0 por miembro/mes para uso individual; límites de plan aplican	Base de datos y dashboard prototipo
Slack Free	\$0 USD; historial searchable 90 días	Avisos HITL y cancelaciones
Telegram APIs	APIs gratuitas; límites operativos aplican	Canal cliente
Túnel HTTPS	No documentado en los archivos recibidos	Verificar proveedor/plan antes de entrega

3. Matriz de decisión de modelos

Tarea	Modelo/modalidad	Motivo	Decisión
Clasificación de intención	Gemini 3.5 Flash-Lite Standard	JSON estructurado, baja latencia, costo bajo	Implementado
Redacción de propiedades	Gemini 3.5 Flash-Lite Standard	Texto breve, contexto acotado	Implementado
Respuesta general/dato faltante	Gemini 3.5 Flash-Lite Standard	Conversación simple	Implementado
Análisis complejo futuro	Gemini 3.6 Flash	Mayor capacidad agentic; costo superior	Escalar solo si métricas justifican
Resumen histórico de miles de interacciones	Gemini 3.5 Flash-Lite Batch	No requiere respuesta inmediata; precio 50% menor	Recomendado
Recalificación masiva nocturna	Gemini 3.5 Flash-Lite Batch	Procesamiento por lotes y ahorro	Recomendado

4. Estimación ilustrativa por volumen

Para disponer de una cifra comparable se usa un escenario explícito, no una medición real: una conversación promedio consume 10.000 tokens de entrada y 500 tokens de salida acumulados entre clasificación y redacción. La cifra real debe medirse en producción.

Conversaciones	3.5 Flash-Lite Standard*	3.5 Flash-Lite Batch*	3.6 Flash Standard*
100	USD 0.43	USD 0.21	USD 1.88
500	USD 2.12	USD 1.06	USD 9.38
1000	USD 4.25	USD 2.12	USD 18.75

Conversaciones	3.5 Flash-Lite Standard*	3.5 Flash-Lite Batch*	3.6 Flash Standard*
5000	USD 21.25	USD 10.62	USD 93.75
10000	USD 42.50	USD 21.25	USD 187.50

* Comparación matemática con el mismo volumen de tokens. Batch no es adecuado para respuestas interactivas al cliente; sirve para ilustrar el ahorro en procesos offline.

5. Palancas de optimización ya presentes

- Modelo Flash-Lite de bajo costo para las tres tareas LLM del MVP.
- Temperatura baja en clasificación de intención para reducir variabilidad.
- Máximo de 3 propiedades recomendadas para limitar contexto y longitud de salida.
- Memoria limitada a 10 interacciones en Notion.
- Dedupe por Telegram Message ID para evitar procesar dos veces el mismo mensaje.
- Scoring de propiedades realizado con Code/Notion, sin gastar tokens del LLM en filtrado mecánico.
- HITL asincrónico por Schedule Trigger, evitando un “wait” bloqueante de larga duración.

6. Brecha frente al criterio literal de Batch

Transparencia de implementación

El JSON actual no contiene una llamada a la API Batch de Gemini. Para cumplir de manera literal el punto de “procesos masivos delegados a Batches”, conviene añadir un subproceso offline (por ejemplo, resumen nocturno de interacciones o recalificación histórica) y documentar su evidencia. La estrategia y el ahorro del 50% quedan definidos aquí, pero no se debe afirmar que Batch ya está operativo.

7. Fuentes de precios

- Google AI for Developers - Gemini Developer API pricing (consultado 12/08/2026): <https://ai.google.dev/gemini-api/docs/pricing>
- Google AI for Developers - Latest Gemini models (consultado 12/08/2026): <https://ai.google.dev/gemini-api/docs/latest-model>
- n8n Docs - self-hosted Community edition (consultado 12/08/2026): <https://docs.n8n.io/choose-how-to-use-n8n/>
- Notion pricing (consultado 12/08/2026): <https://www.notion.com/pricing>
- Slack pricing (consultado 12/08/2026): <https://slack.com/pricing>
- Telegram APIs (consultado 12/08/2026): <https://core.telegram.org/>